按「接下来三天」截图逐条验收报告

验收日期：2026-10-13（America/Chicago）。原始实验日志采用 UTC，因此部分文件名为 20261014。核验基线：Git `4bf59692b06fce3bd4d3153a2319804aec931ca3`，沿用 Python 3.12.10、`deepseek-flash`、原 FastAPI / Streamlit 项目。

本报告按照用户提供的截图顺序，列出共同工作、10/12 A/B 工作、10/13 D4 和 10/14 D5，共 **17 个验收条目**。依据是原任务截图、12号任务原文和总方案。截图作为验收清单，历史测试以实际原始结果为准。

当前结论：D4 四项工作及此前八项技术修复已有实现和开发实测；共同审核的填写已经收齐，但题面、标签及两道新 gold 的草稿尚未全部版本化应用。D5 尚未执行。 不将开发集 EX、自动检查或 AI 核对写成人工语义通过；不将不同版本补测拼成一次完整运行。

包内路径均相对项目根目录。请完整解压，再打开根目录的「先看这里.html」或本报告 HTML。PDF 可直接阅读；查看源码、原始响应和截图附件请使用 HTML。历史报告保留当时状态，本报告描述本次核验的状态。

一、10/11 晚或 10/12 早：一起拍板

01．拍板上面 5 条口径

要求： 两人确认地区、缺期间、谁买得最多、金额占比、老美别名的处理范围。

实现与改动： 五项已有用户任务文件的明确授权，已接入 `qa_agent/clarify/`、金额占比校验及版本化别名索引。

拍板项	当前实际规则	核验结果
地区默认	发票 / 销售额按账单国家；客户类按客户所在地；显式指定优先	2024 巴西两种来源均真实通过
没说期间	仅授权的热门曲目、复购、客户排名按全部数据；前轮已定年份继续保留	复购59人；续问前5位保留2023；年份来自实际目录
谁买得最多	当前 Chinook 场景默认客户消费金额；热门曲目仍按购买数量	客户金额、曲目数量两种真实请求均通过
金额占比分母	发票金额 / 销售额占比按同期全部发票金额；不能套到客户数量占比	France2024及续问德国分子通过，错误分母反例被拒绝
老美	客户国家、账单国家的两条关系直接链接 USA；其他条件明确时 L0	真实客户COUNT13、L0；未扩大到其余别名

测试与证据： 12号任务五项授权原文；10月12日逐项报告 12-01 ~ 12-05；定向实际回答目录；复购等补测目录。改动：rules.py、extractor.py、ratio_guard.py、aliases-oct12-approved.csv。

验收：已实现并实测。限制： “谁买得最多”缺 N 的通用 Top10 与 sp03-19 历史 Top1 参考存在争议，历史失败不放宽行数。没有批准裸“占比”自行猜分子。

02．过一遍统一待人工审核表：去重、删题面指令、改标签

要求： 统一已有待核材料，同类放在一起，分别处理参考答案、实际回答和引用，不把题面中的模型操作指令当业务约束。

实现与改动： 已有统一入口和去重、清洗、标签草稿。用户提交双方审核后的 HTML 后，仅检查是否漏填，保留双方原结论。**735 个唯一编号一致、内容哈希一致；2470 个审核选择全部非空；735 项描述、标签、处理说明均无遗漏；94 个新 SQL 框有内容。** 别名和说明条目无需 SQL，空 SQL 框不算漏填。选择数量不等于题目数量。

测试与证据： 统一入口 HTML；统一入口原数据；提交内容提取记录；完整性检查。完整性检查字段：`rows=735`、`unique_ids=735`、`unfilled_choices=[]`，三个 `unfilled_required_text_fields` 均为空。相关源码：build_oct12_review.py、check_oct12_review.py。

验收：审核填写完整；应用草稿仍待落地。 当前保存 / 导出不会自动删除题目、改标签、替换题面、启用别名或填写人工日期。双方提交的草稿已收齐，尚不能宣称所有清洗和标签已进入正式题库。证据不足的别名也没有因“表填完”而自动启用。sp03-19的提交草稿已经明确只取第一名，sp01-30也已提交日期上界修正；两项尚未应用，不能继续当成你们没填，也不能追改旧运行成绩。

03．定 sql-38、robust-23 两个新 gold

要求： 明确 NULL 排名和“这批曲目”的范围，以新版本保存题面、SQL、结果、边界及来源，再补测受影响开发题。

已有材料： 双方提交草稿中的 sql-38 采用文件大小已知的曲目排名，SQL 包含 `WHERE bytes IS NOT NULL`；robust-23 改为明确全库曲目、逐曲目等权 AVG，单位毫秒。两条新参考选择为“有条件通过”。只读提案核验 **13/13** 查询成功；3503 条曲目的 bytes 与 milliseconds 当前 NULL 数均为0；平均时长 `393599.212103910933` 毫秒，文件大小前三名在提案中。

实际差异： 当前 D2 开发视图的 sql-38 仍使用 `NULLS LAST`，没有 `WHERE bytes IS NOT NULL`；冻结原题库仍保留旧版本。robust 开发视图已用“全部曲目”表述，但正式原题库仍有“这批曲目”。当前值相同不能证明两个 NULL 口径相同。

证据： 新 gold 说明与选项；结构化提案；双方提交草稿，按 `sql:sql-38`、`robust:robust-23` 定位；13条只读验证和实际查询；当前 SQL DEV 视图，第29行；当前 robust DEV 视图，第16行。

验收：新定义和草稿已收齐、只读依据齐全；正式版本化应用及按新题补测尚未完成。 本次报告和打包没有顺手修改 gold 或回填旧成绩，后续应把双方草稿落成新版本并保留旧记录。

二、10/12 D3：A 线——修回归和评测

04．跨表校验回归（最急）

要求： 取消“只有值绑定到 artist / genre / media_type 才准 JOIN”的限制；按实际 FK 校验，禁止修复换过滤字段绕过。

实现与改动： pipeline.py、validator.py、repair_guard.py已接入真实关联和修复筛选保护。错误 FK、CROSS、OR 绕过及改列 / 改值 / 改范围反例均有模块覆盖。

测试与实际结果： 新增15题 JOIN 实跑首轮14/15；员工姓名范围修复后第二轮 **15/15**，未为通过而更改 gold。原完整失败及修复记录保留。后来 D4 全模块及数据库集成实际 **729 passed、0 skipped、16.10秒**；AW21道两组各21/21支持当前跨表流程，但不等同证明所有复杂 SQL 的语义。

证据： JOIN首轮、JOIN第二轮、修复记录、对应测试、最终模块输出。**验收：实现与开发回归完成。**

05．linker 分数下限、时间词停用表

要求： 低分 fuzzy / 向量候选不进入澄清卡；每年、今年等时间词不当实体。

实现与改动： linker.py候选下限 fuzzy 0.60、vector 0.65，与自动绑定门槛分开；rules.py保留期间语义并修复完整日期被误读为月份的窄问题。

测试与实际结果： sp03-14 每年输出2022、2023且不再产生0分实体；Gudian流派真实链接 Classical74；日期修复独立22项通过。sql-22 真实单题补测 **1/1**，严格早于2004-01-01只保留结束边界，没有虚构开始日期。

证据： sp03-14原始回答、sp01-22原始回答、日期二审探针、sql-22补测、NLU测试。**验收：实现与实测完成。限制：** 阈值没有用保留集调优；最后单题补测不写成整轮35/35。

06．评测加方案口径的 EX

要求： 主 EX 忽略列名、允许额外描述列，同时保留旧 EX；不得放宽行数、重复行及明确排序。

实现与改动： eval/metrics.py、eval/run_eval.py采用稳定列映射，只允许可证明的直接文字 / 主键描述列；不是任意多列都通过。

测试与实际结果： 新旧 EX 逐题并存。热门曲目附名称的输出主 EX 通过，旧 EX 因列数失败；sp03-19 多9行仍判错。10/12最后整轮 SQL **34/35** 、robust **21/21** ；后续 sql-22 单独补测1/1。D4 AW两组各21/21、SQL规模各60/60，均保存新旧 EX。

证据： 指标测试、10/12整套原始报告、最后35题SQL报告、AW对照、SQL规模报告。**验收：主指标实际接入且实跑。限制：** EX不代替业务口径、gold及回答语义核对。

07．补 10–15 道带 JOIN 的题

要求： 用自然口语题覆盖艺术家、媒体、雇员、客户和购买明细关联，避免继续只有单表题。

实现与改动： 新增 **15 道、全部 DEV** ，包含错拼、未知流派、空结果、零计数。源码：build_oct12_join_dev.py；题库：chinook_join_dev_v1.jsonl。

测试与实际结果： 15条参考 SQL 全部只读执行；首轮真实14/15，第二轮 **15/15** 。**证据：** 参考生成记录、首轮、第二轮。**验收：数量、执行与真实回归完成；参考标签的人工落地状态见共同审核条目02，不能自动改为 approved。**

三、10/12 D3：B 线——改规则和文案

08．规则按拍板结果改成 L1

要求： 授权默认可以继续查询，向用户说明当前口径并允许切换；显式指定及已确认条件优先。

实现与改动： clarify_rules.yaml、rules.py、service.py已接入授权默认与会话合同；界面展示可切换假设。已明确授权的“老美”在条件明确时为 **L0** ，不是为了匹配标题强行改成L1。

测试与实际结果： 默认地区、显式客户所在地、缺期间、客户金额 / 曲目数量真实请求通过；前轮2023年份在续问保留。17项定向第二轮单轮 **14/17** ，两个网络失败独立补测2/2后，逐题最新摘要为 **16/17** ，仍有 sp03-19 Top1 / Top10争议。

证据： 定向第二轮、独立补测、10/12报告。**验收：授权规则已生效；不能称所有定向题一次性17/17。**

09．合并重复的期间问题，补抽分子

要求： 同比同一期间缺口只问一次，明确 France 等占比分子不能漏掉；续问只修改所指条件。

实现与改动： extractor.py、rules.py、service.py合并期间槽位、区分当前 / 基期，并提取金额占比分子。D4继续修复裸占比自造分子和删除筛选失效。

测试与实际结果： sp03-06 首问期间缺口数 **1** ，补2024对2023后真实通过；sp03-22明确分子通过。原 sp03-26/27/28 最终14轮合同、10个有参考SQL的结果均通过。**证据：** 同比实际回答、占比实际回答、D4最终多轮逐轮报告。**验收：实现与实际回归完成。**

10．RAG 核验不过时标“未核实”

要求： 数字校验失败先重生成一次，仍不过正常返回并标“未核实”；引用ID、文档归属等硬错误不能一起降级。

实现与改动： rag/answer.py、rag/service.py已接入有界重试和警告；test_oct12_rag_ui.py覆盖降级及引用硬错。

测试与实际结果： 实际 rag-03 在 run003 两次数字校验均失败，回答及“未核实”警告真实可见；run004该题首答取到上下文后机械核验通过，两轮分别保留。10/12 RAG21题状态20成功、1空结果，不能把状态成功称完整语义正确。

证据： run003原始回答、警告截图、run004报告。**验收：实际触发过降级分支。限制：** “未核实”不是答案忠实度通过；数字出现在片段不代表整句话有支持。

11．界面文案改成给用户看的

要求： 显示可理解的改写依据 / 分数与业务澄清理由；比例和增长率显示百分比，原始结果可追溯。

实现与改动： ui/app.py、result_format.py、multi_table.txt已接入展示文案及格式化副本，不用内部候选ID作为主要说明。

测试与实际结果： run004 **5/5 真实页面场景、33/33检查**；拼音实际分数1.00、比例11.20%、增长率24.24%，raw保留fraction。早先run003为33/36，失败未删除。之后只有日期规则窄修复，UI / RAG组件SHA不变，未把旧截图称成新代码全量重拍。

证据： 页面报告、逐张截图核对、5张实际截图目录。**验收：实现、实际页面及截图核验完成。**

四、10/13 D4：A 线——效率与④消融

12．效率测试：至少两档数据规模

要求： 同一批开发问题，各规模每题3次；数据库至少1万 / 10万明细独立副本，文档10 / 100页；分别统计模型、SQL / 检索和端到端 P50 / P90。

实现与改动： scale_data.py、d4_sql_scale.py、d4_rag_scale.py、retriever.py。独立 schema 不扩写 public；11条真实FK、0孤儿、发票与明细金额核对通过。原业务表逐行 checksum前后不变。文档扩容后所有候选片段实际参与搜索。

规模与次数	实际规模	正确性或状态	端到端 P50 / P90（ms）
SQL原库：20题×3	2240明细 / 412发票	主EX与旧EX60/60	3697.432 / 4213.883
SQL1万：同20题×3	10000明细 / 2060发票	重新计算本副本gold，60/60	3755.084 / 4219.519
SQL10万：同20题×3	100000明细 / 18540发票	重新计算本副本gold，60/60	3855.098 / 4247.997
RAG10页：20题×3	228片段 / 5份开发文档	页Hit@5 60/60；57成功、3空结果	2977.521 / 5971.322
RAG100页：同20题×3	1876片段 / 5份开发文档	页Hit@5 60/60；57成功、3空结果	3028.816 / 3948.990

阶段 P50 / P90（ms）	SQL原库	SQL1万	SQL10万
纯模型调用	2680 / 3103.4	2752 / 3186.2	2801 / 3140.4
SQL生成阶段	3587 / 3985.9	3687.5 / 4069.4	3746 / 4055.6
SQL执行	25.5 / 36	25.5 / 38	32.5 / 41.2

RAG检索 P50 / P90：10页 **52 / 77.6ms**，100页 **134.5 / 182.1ms**；回答阶段为2921 / 5922.5、2865 / 3761.9ms。以上阶段不可直接相加求分位数。

判断与限制： SQL共180次、RAG共120次实跑。SQL题中仅3题查询 invoice_line，7题invoice、10题维表控制；不能把总耗时小幅变化推广到所有大表扫描。独立EXPLAIN全明细SUM实际扫描2240 / 10000 / 100000行，执行0.388 / 1.613 / 15.441ms。RAG两个 rag-03变体在两档共6次缺少关键答案片段；页命中不能计作完整答案正确。RAG启发式匹配38/60、39/60不作为语义准确率。压测副本年份延至2045 / 2245，明确是合成压力数据，业务库仍2021—2025。

证据： 数据规模manifest、SQL实际汇总、SQL逐题结果、RAG汇总、RAG原始回答、规模与成本完整说明、真实命令目录。**验收：实际规模、关联核对、正确性检查、阶段耗时及P50/P90齐全；RAG语义限制已披露。**

13．④消融：全量 schema 对比子图

要求： 同一AW、同21道DEV；全量与④两组走相同生成 / 校验 / 执行 / 评分；统计④自身模型调用及耗时，不给筛选器gold表名。前置完整④还须剪枝、理由及连通检查。

实现与改动： schema_linker.py、pruner.py、d4_aw_ablation.py、ui/app.py。实际FK补桥、已绑定字段保护、入选 / 排除理由及连通性已接入；模型只从真实候选选取。全量组直接使用68表 / 456列 / 90FK登记目录。

同21题指标	全量组	④子图组
主EX / 旧EX	21/21 / 21/21	21/21 / 21/21
已回报全链路输入token	832958	243694
SQL生成输入token	795212	48207
④选表输入token	0（未调用）	157741
端到端P50 / P90 ms	4747.472 / 5438.653	8172.456 / 15855.341
实际模型尝试	22	44

判断： 已回报全链路输入减少 **70.74%**，SQL生成输入减少93.94%；本次准确率没有提高、整体没有提速。aw-07子图首尝试剪枝超时61417ms，重试成功，整条69871.848ms保留；失败尝试未回报usage，不能把未知token当0或把已知合计当完整账单。只有两主组、21题单次成对运行，未声称统计显著性或四组完整消融。

测试与证据： 两组真实汇总、42条实际响应、逐题SQL / 评分、原始provider记录、13/13实际理由页面检查、理由截图。**验收：对照与前置功能完成；结论是减少已回报输入，同时增加本次端到端耗时。9道AW保留题未预测。**

五、10/13 D4：B 线——多轮与跨源

14．多轮补丁与失效：sp03-26 / 27 / 28

要求： 先复现三段失败，再5段×至少6轮；保存结构化 IntentContract，set / add / remove合并、version加1、旧计划 / 结果失效并重查；分别统计每轮条件和整段成功。

实现与改动： clarify/state.py、extractor.py、service.py、sql_guard.py、pipeline.py。修复旧筛选恢复、TopN不更新、旧指标排序、额外投影、裸占比猜分子及删除筛选；不以聊天历史重新猜替代合同合并。

最终004范围	条件 / 版本	参考SQL轮主EX / 全精度	整段成功
原sp03-26/27/28，5/5/4轮	14/14 / 14/14	10/10 / 10/10	3/3
新五段，各6轮	30/30 / 30/30	30/30 / 30/30	5/5
合计	44/44 / 44/44	40/40 / 40/40	8/8

版本说明： 新第4段最终采用独立 **04-v2** ，只在首句添加“降序”，后5句和所有gold SQL不变。原04未明确主方向，其旧输出及DESC gold争议保留，不能将明确版5/5写成原版5/5。原三段包含4次必要澄清；新30轮没有重复追问已确认条件。原首轮原三段1/3、新五段1/5及中间失败均保留。

证据： 修复说明、最终逐轮报告、最终题面与标准材料、各段原始输入输出目录、实际命令、原04失败。**验收：补丁、失效、原失败回归及明确版五段验收完成；新增材料人工核对及原04方向保留。**

15．两类跨源：SQL→文档、文档→SQL

要求： 前一步的真实结果决定后一步输入；同一请求串起数据库与文档，复用已有SQL、RAG和③；6道跨源题、实际界面显示两步。

实现与改动： fusion/planner.py已经实现，截图中的“目录还是空的”属于历史观察。SQL→文档先查冠军ID / 名称，再按 `entity_ref` 精确匹配介绍；文档→SQL先检索客单价逐字定义，把聚合、粒度、字段及源SHA送入真实生成输入并执行前校验。未把文档原SQL绕过校验直接执行。

开发题	最新007实际结果
cross-01	全库冠军Iron Maiden，artist_id90、138.60，匹配风格文档引用
cross-02	2024冠军Iron Maiden、33.66，期间与文档匹配
cross-03	范围只有U2介绍时保留真实冠军，返回文档不足；不借用U2资料
cross-04	手册定义驱动2024美国客户逐发票均额6.0942857142857143，21票127.98
cross-05	手册定义驱动2023加拿大客户逐发票均额5.04，11票55.44
cross-06	缺年先NEEDS_CLARIFICATION且无SQL，同session补2024后查询、version1→2

测试与实际结果： 融合模块47/47；最新007 **6/6 符合预期** ，7次API请求，其中5题完成两步、1题按范围正确返回不足。两类完整界面检查合计 **24/24** ，分别来自UI002和UI003两次运行；截图对应005，不伪称007重拍。实际provider输入确认定义真正参与SQL计划。

证据： 六道DEV题、最新API汇总、逐句答案 / 引用及生成输入复核、SQL→文档截图、文档→SQL截图、两类完整界面记录、第二类补测。**验收：两类实际接入、六题及页面联调完成；新六题语义仍保留人工核对。**

六、10/14 D5：截图中尚未执行的安排

16．15:00 代码冻结

要求： 在约定时点固定代码、配置、题库和口径版本，之后只能按明确流程处理问题。

当前状态：尚未执行。 当前有Git提交及实验源码哈希用于追溯，这是D4实验版本记录，不是D5正式冻结。没有创建D5冻结标记、没有将本次打包时间代填为10/14 15:00。

已有证据： D4实测源码清单、对应原字节源码、最终回归退出码。**后续事项：** 冻结前先应用需要落地的已提交审核决定，确认两gold及新增材料；冻结具体时区需团队明确，不从客户端时区猜比赛截止口径。

17．上午全量评测修错；冻结后再跑一遍，生成 final.md

要求： 冻结前开发验证和修错；冻结后固定版本运行全量正式评测、生成final.md，保留集按原方案边界运行。

当前状态：尚未执行。 本轮只有已有DEV实验、模块与实际入口复核，没有提前调用保留题，没有生成D5正式成绩或final.md。旧D1、D2、D3报告中的“final”目录名称不是D5正式冻结报告。

已具备条件： 当前729模块通过、双数据库恢复且只读5秒超时、评测新旧EX并存、阶段原始响应和版本追溯齐全。**仍需处理：** 共同条目02 / 03的草稿应用、原04方向与D4新增题目 / 变体人工核对；RAG缺答案片段及sp03-19参考合同争议要如实处理，不能靠改历史成绩消除。

七、本次交付核验、入口和附件

本次实际运行 `pwsh -NoProfile -File scripts/start_project.ps1 -NoBrowser`，退出0，复用Chinook、AW、API和界面；未导入数据库、未发送模型问答。当前页面 `http://127.0.0.1:8501/`，API文档 `http://127.0.0.1:8000/docs`。本次入口命令 / 输出 / 健康记录独立保存，不回填到旧实验日志。

在你目前这台电脑上： 进入原项目目录，双击启动项目.cmd，浏览器打开上述主页面。不要用解压到另一路径的副本启动同端口服务；本机既有环境继续用原项目。审核入口是独立HTML，不能代替8501的项目主界面。

给他人或换电脑： 完整解压ZIP，先打开根目录先看这里.html，再按项目入口与换电脑运行说明安装Python3.12依赖、配置自己的密钥 / 密码、首次建立独立Docker库，然后双击启动项目.cmd。本ZIP包含已有BGE-M3权重、文档 / 值 / AW结构索引、公开原PDF和AW数据，不需重新造题或重新下载模型才能看证据。Python虚拟环境、Docker运行卷及真实凭据不能直接移植，需按说明配置。

附件范围： 项目源码与system prompt、测试、历史D1～D4报告、实际命令和原始响应 / 日志、截图、双方审核提取记录、原始公开数据、模型及索引。排除真实.env、所有.runtime私有文件、Git内部文件、虚拟环境、Python缓存及临时目录。历史题库完整保留，仅用于原计划阶段；本次没有阅读或运行新的保留题内容，也不在本报告展开保留题答案。

最终ZIP的文件清单和各文件SHA256在根目录 `delivery-manifest.json`；密钥扫描、CRC、解压字节校验、相对证据链接和未改变业务源码检查记录在根目录 `交付包核验.json`。最终压缩包自身的大小、SHA256及全部检查结果另保存在压缩包旁的核验JSON，避免将ZIP自身哈希循环写入ZIP。打开附件需要整个ZIP解压，不能只转发HTML或在压缩预览器中点证据。

验收边界汇总： 12个技术条目（04～15）有实现及实际开发证据；01五项口径已生效；02审核收齐但草稿未全部应用，03新gold未正式版本化及补测；16～17为D5尚未执行。保留旧失败、待核限制及人工决定来源，报告不填A/B签名，不自动改人工审核状态。