按「接下来三天」截图逐条验收报告

验收更新：2026-10-14（America/Chicago）。原始实验日志采用 UTC；`manual-applied-20261013-v3` 是沿用原审核批次的版本名，实际补测时间见命令记录。核验基线：Git `4bf59692b06fce3bd4d3153a2319804aec931ca3`，沿用 Python 3.12.10、`deepseek-flash`、原 FastAPI / Streamlit 项目。

本报告按照用户提供的截图顺序，列出共同工作、10/12 A/B 工作、10/13 D4 和 10/14 D5，共 **17 个验收条目** 。依据是原任务截图、12号任务原文和总方案。截图作为验收清单，历史测试以实际原始结果为准。

当前结论：02 的双方审核已正式应用，03 的两道新 gold 已版本化保存并真实补测 2/2 通过。D4 四项工作及此前八项技术修复的历史开发证据保留；本轮新增专项回归仍发现多轮问题，见本报告最后的限制说明。D5 尚未执行。 不将开发集 EX、自动检查或 AI 核对写成人工语义通过；不将不同版本补测拼成一次完整运行。

包内路径均相对项目根目录。请完整解压，再打开根目录的「先看这里.html」或本报告 HTML。PDF 可直接阅读；查看源码、原始响应和截图附件请使用 HTML。历史报告保留当时状态，本报告描述本次核验的状态。

一、10/11 晚或 10/12 早：一起拍板

01．拍板上面 5 条口径

要求： 两人确认地区、缺期间、谁买得最多、金额占比、老美别名的处理范围。

实现与改动： 五项已有用户任务文件的明确授权，已接入 `qa_agent/clarify/`、金额占比校验及版本化别名索引。

拍板项	当前实际规则	核验结果
地区默认	发票 / 销售额按账单国家；客户类按客户所在地；显式指定优先	2024 巴西两种来源均真实通过
没说期间	仅授权的热门曲目、复购、客户排名按全部数据；前轮已定年份继续保留	复购59人；续问前5位保留2023；年份来自实际目录
谁买得最多	当前 Chinook 场景默认客户消费金额；热门曲目仍按购买数量	客户金额、曲目数量两种真实请求均通过
金额占比分母	发票金额 / 销售额占比按同期全部发票金额；不能套到客户数量占比	France2024及续问德国分子通过，错误分母反例被拒绝
老美	客户国家、账单国家的两条关系直接链接 USA；其他条件明确时 L0	真实客户COUNT13、L0；未扩大到其余别名

测试与证据： 12号任务五项授权原文；10月12日逐项报告 12-01 ~ 12-05；定向实际回答目录；复购等补测目录。改动：rules.py、extractor.py、ratio_guard.py、aliases-oct12-approved.csv。

验收：已实现并实测。限制： “谁买得最多”缺N的通用Top10与sp03-19旧Top1参考曾有争议；新版sp03-19已按双方草稿明确第一名，历史失败不放宽行数。没有批准裸“占比”自行猜分子。

02．过一遍统一待人工审核表：去重、删题面指令、改标签

要求： 使用两人已经提交的审核结果，正式落地去重、题面清洗和标签；分开保留参考答案、系统回答和引用的判断，不能把证据不足别名直接启用。

实现与改动：已正式完成。 直接复用双方已完成的735项审核，不要求重复审核。735个唯一编号及来源哈希逐项一致，2470个审核选择均完整，必填描述 / 标签 / 处理说明无遗漏。正式应用结果逐项记录原决定及目标文件，**735项有正式处理目标、0项遗漏** 。其中194条DEV题库记录、524项AW目录说明、2项未启用别名关系和15项共同 / 诊断记录分别进入对应文件；2470个选择不是2470道题。

当前正式开发题库为 `manual-applied-20261013-v3`，通过 current.json 接入原评测入口。七组共194条记录、190条活动题；专项重复题sp01-13归档，三条缺唯一含义题保留诊断；17条题面修改及审核标签、限定条件已经应用。sp03-19正式题面明确Top1；sp01-30按已提交草稿修正日期上界。原题库、原实际回答和原评分不追改。

运行时AW目录为68表456列，524项描述决定进入新目录与真实BGE索引；81项别名中56项直接使用、23项仅候选、2项证据不足停用。候选审批不自动绑定唯一对象；“金属→Metallica”和“节奏摇滚→Rock And Roll”未启用。新版值索引含79项启用关系，沿用现有5607条实体值记录；没有改实际数据库结构或导入数据。

测试与实际结果： 165条标准 / 必要续问与条件分支SQL在qa_reader只读事务、5秒限制下实际执行成功；源题库 / 目录 / 别名及384个历史证据来源哈希未变。最终完整模块回归 **782 passed，0 skipped，17.41秒** 。新开发实跑SQL35题34/35、鲁棒21题21/21；sql-38独立修复补测与两题最终2/2见03，不能拼成一次35/35。AW首轮20/21和单题回归分开保存，专项29场景16/29整体通过如实保留，详见限制。

证据： 735项正式应用结果HTML、对应逐项JSON；题库manifest、194条逐项old→new、标准SQL执行证据；新AW目录、新别名表、索引实建记录、运行路径生效记录。实现：题库应用脚本、目录别名应用脚本、正式审核记录应用脚本、现有评测入口、新版题库定位。

验收：正式应用完成。 “证据不足”“有条件通过”等决定按双方原选择和范围落地，不代填A/B签名或人工日期，不将未预测保留题写成已通过。原统一审核HTML保留为原始材料；现在查应用位置请使用上面的735项正式应用结果。

03．定 sql-38、robust-23 两个新 gold

要求： 将双方确定的新题面、标准SQL、真实结果和边界正式版本化保存，并按新版本补测。

实现与改动：已正式完成。 复用735项审核中两道题的最终提交内容，写入当前v3正式开发题库。完整题目对象包括新题面、标准SQL、gold行列 / 类型、审核范围、条件和来源哈希；两gold独立正式清单保存旧→新映射，sql-38标准SQL与robust-23标准SQL可直接阅读。旧版本及旧成绩保留，不覆盖历史答案。

编号	正式新题面	新标准SQL及结果
sql-38	找出文件大小已记录的曲目中，字节数最大的前3首，返回曲目编号、名称和字节数；按字节数降序，并列按曲目编号升序。	`WHERE bytes IS NOT NULL ORDER BY bytes DESC, track_id ASC LIMIT 3`；3224 / 1059546140、2820 / 1054423946、3236 / 587051735；完整名称见下表
robust-23	库里所有曲目的平均长度是多少毫秒?	`SELECT AVG(milliseconds) AS average_milliseconds FROM public.track;`； `393599.212103910933` 毫秒

sql-38完整标准SQL：

```
SELECT track_id, name, bytes
FROM public.track
WHERE bytes IS NOT NULL
ORDER BY bytes DESC, track_id ASC
LIMIT 3;
```

track_id	name	bytes
3224	Through a Looking Glass	1059546140
2820	Occupation / Precipice	1054423946
3236	The Young Lords	587051735

测试与实际结果： 首轮新版SQL35题中的sql-38误触发澄清，鲁棒21题中的robust-23通过。针对完整“曲目字段排名”证明做最小识别修复，保留条数 / 条件 / 主排序 / 并列顺序；没有将业务排名的缺失指标全局放行，也没有改 system prompt。重启同一API后，两条原样v3 DEV题独立实跑，**2题预测、2题通过、0保留题预测** 。检查实际SQL的NULL筛选、字段、排序、LIMIT，以及全库AVG、单位和全精度结果；不能仅凭当前库NULL数为0及结果巧合相同验收NULL逻辑。

证据： 最终两题实际报告、机器报告及版本哈希、两题原始响应、独立逐项复核、实际命令及输出、新题面原样子集及来源；首轮SQL34/35、首轮鲁棒21/21、NULL边界只读依据。最小修复：extractor.py、边界测试说明。

验收：新题面、SQL、标准结果已正式版本化，按该版本真实补测2/2通过。 保留双方“有条件通过”的条件，不填写人工确认日期；此处完成状态指双方已确定范围内的版本保存与补测，不代表替代人工签字。展示限制：robust自然语言答复未再次写“毫秒”，但实际字段和查询没有换算；sql-38结构化过滤列表为空，原题和执行SQL的非NULL条件正确。本轮验收只覆盖实际单轮查询，不声称其后续多轮属性修改已验证。

二、10/12 D3：A 线——修回归和评测

04．跨表校验回归（最急）

要求： 取消“只有值绑定到 artist / genre / media_type 才准 JOIN”的限制；按实际 FK 校验，禁止修复换过滤字段绕过。

实现与改动： pipeline.py、validator.py、repair_guard.py已接入真实关联和修复筛选保护。错误 FK、CROSS、OR 绕过及改列 / 改值 / 改范围反例均有模块覆盖。

测试与实际结果： 新增15题 JOIN 实跑首轮14/15；员工姓名范围修复后第二轮 **15/15** ，未为通过而更改 gold。原完整失败及修复记录保留。后来 D4 全模块及数据库集成实际 **729 passed、0 skipped、16.10秒** ； AW21道两组各21/21支持当前跨表流程，但不等同证明所有复杂 SQL 的语义。

证据： JOIN首轮、JOIN第二轮、修复记录、对应测试、最终模块输出。**验收：实现与开发回归完成。**

05．linker 分数下限、时间词停用表

要求： 低分 fuzzy / 向量候选不进入澄清卡；每年、今年等时间词不当实体。

实现与改动： linker.py候选下限 fuzzy 0.60、vector 0.65，与自动绑定门槛分开；rules.py保留期间语义并修复完整日期被误读为月份的窄问题。

测试与实际结果： sp03-14 每年输出2022、2023且不再产生0分实体；Gudian流派真实链接 Classical74；日期修复独立22项通过。sql-22 真实单题补测 **1/1** ，严格早于2004-01-01只保留结束边界，没有虚构开始日期。

证据： sp03-14原始回答、sp01-22原始回答、日期二审探针、sql-22补测、NLU测试。**验收：实现与实测完成。限制：** 阈值没有用保留集调优；最后单题补测不写成整轮35/35。

06．评测加方案口径的 EX

要求： 主 EX 忽略列名、允许额外描述列，同时保留旧 EX；不得放宽行数、重复行及明确排序。

实现与改动： eval/metrics.py、eval/run_eval.py采用稳定列映射，只允许可证明的直接文字 / 主键描述列；不是任意多列都通过。

测试与实际结果： 新旧 EX 逐题并存。热门曲目附名称的输出主 EX 通过，旧 EX 因列数失败；sp03-19 多9行仍判错。10/12最后整轮 SQL **34/35** 、robust **21/21** ； 后续 sql-22 单独补测1/1。D4 AW两组各21/21、SQL规模各60/60，均保存新旧 EX。

证据： 指标测试、10/12整套原始报告、最后35题SQL报告、AW对照、SQL规模报告。**验收：主指标实际接入且实跑。限制：** EX不代替业务口径、gold及回答语义核对。

07．补 10–15 道带 JOIN 的题

要求： 用自然口语题覆盖艺术家、媒体、雇员、客户和购买明细关联，避免继续只有单表题。

实现与改动： 新增 **15 道、全部 DEV**，包含错拼、未知流派、空结果、零计数。源码：build_oct12_join_dev.py；题库：chinook_join_dev_v1.jsonl。

测试与实际结果： 15条参考 SQL 全部只读执行；首轮真实14/15，第二轮 **15/15** 。**证据：** 参考生成记录、首轮、第二轮。**验收：数量、执行与真实回归完成；参考标签的人工落地状态见共同审核条目02，不能自动改为 approved。**

三、10/12 D3：B 线——改规则和文案

08．规则按拍板结果改成 L1

要求： 授权默认可以继续查询，向用户说明当前口径并允许切换；显式指定及已确认条件优先。

实现与改动： clarify_rules.yaml、rules.py、service.py已接入授权默认与会话合同；界面展示可切换假设。已明确授权的“老美”在条件明确时为 **L0**，不是为了匹配标题强行改成L1。

测试与实际结果： 默认地区、显式客户所在地、缺期间、客户金额 / 曲目数量真实请求通过；前轮2023年份在续问保留。17项定向第二轮单轮 **14/17**，两个网络失败独立补测2/2后，逐题最新摘要为 **16/17**，仍有 sp03-19 Top1 / Top10争议。

证据： 定向第二轮、独立补测、10/12报告。**验收：授权规则已生效；不能称所有定向题一次性17/17。**

09．合并重复的期间问题，补抽分子

要求： 同比同一期间缺口只问一次，明确 France 等占比分子不能漏掉；续问只修改所指条件。

实现与改动： extractor.py、rules.py、service.py合并期间槽位、区分当前 / 基期，并提取金额占比分子。D4继续修复裸占比自造分子和删除筛选失效。

测试与实际结果： sp03-06 首问期间缺口数 **1**，补2024对2023后真实通过；sp03-22明确分子通过。原 sp03-26/27/28 最终14轮合同、10个有参考SQL的结果均通过。**证据：** 同比实际回答、占比实际回答、D4最终多轮逐轮报告。**验收：实现与实际回归完成。**

10．RAG 核验不过时标“未核实”

要求： 数字校验失败先重生成一次，仍不过正常返回并标“未核实”；引用ID、文档归属等硬错误不能一起降级。

实现与改动： rag/answer.py、rag/service.py已接入有界重试和警告；test_oct12_rag_ui.py覆盖降级及引用硬错。

测试与实际结果： 实际 rag-03 在 run003 两次数字校验均失败，回答及“未核实”警告真实可见；run004该题首答取到上下文后机械核验通过，两轮分别保留。10/12 RAG21题状态20成功、1空结果，不能把状态成功称完整语义正确。

证据： run003原始回答、警告截图、run004报告。**验收：实际触发过降级分支。限制：** “未核实”不是答案忠实度通过；数字出现在片段不代表整句话有支持。

11．界面文案改成给用户看的

要求： 显示可理解的改写依据 / 分数与业务澄清理由；比例和增长率显示百分比，原始结果可追溯。

实现与改动： ui/app.py、result_format.py、multi_table.txt已接入展示文案及格式化副本，不用内部候选ID作为主要说明。

测试与实际结果： run004 **5/5 真实页面场景、33/33检查**；拼音实际分数1.00、比例11.20%、增长率24.24%，raw保留fraction。早先run003为33/36，失败未删除。之后只有日期规则窄修复，UI / RAG组件SHA不变，未把旧截图称成新代码全量重拍。

证据： 页面报告、逐张截图核对、5张实际截图目录。**验收：实现、实际页面及截图核验完成。**

四、10/13 D4：A 线——效率与④消融

12．效率测试：至少两档数据规模

要求： 同一批开发问题，各规模每题3次；数据库至少1万 / 10万明细独立副本，文档10 / 100页；分别统计模型、SQL / 检索和端到端 P50 / P90。

实现与改动： scale_data.py、d4_sql_scale.py、d4_rag_scale.py、retriever.py。独立 schema 不扩写 public；11条真实FK、0孤儿、发票与明细金额核对通过。原业务表逐行 checksum前后不变。文档扩容后所有候选片段实际参与搜索。

规模与次数	实际规模	正确性或状态	端到端 P50 / P90（ms）
SQL原库：20题×3	2240明细 / 412发票	主EX与旧EX60/60	3697.432 / 4213.883
SQL1万：同20题×3	10000明细 / 2060发票	重新计算本副本gold，60/60	3755.084 / 4219.519
SQL10万：同20题×3	100000明细 / 18540发票	重新计算本副本gold，60/60	3855.098 / 4247.997
RAG10页：20题×3	228片段 / 5份开发文档	页Hit@5 60/60；57成功、3空结果	2977.521 / 5971.322
RAG100页：同20题×3	1876片段 / 5份开发文档	页Hit@5 60/60；57成功、3空结果	3028.816 / 3948.990

阶段 P50 / P90（ms）	SQL原库	SQL1万	SQL10万
纯模型调用	2680 / 3103.4	2752 / 3186.2	2801 / 3140.4
SQL生成阶段	3587 / 3985.9	3687.5 / 4069.4	3746 / 4055.6
SQL执行	25.5 / 36	25.5 / 38	32.5 / 41.2

RAG检索 P50 / P90：10页 **52 / 77.6ms**，100页 **134.5 / 182.1ms**；回答阶段为2921 / 5922.5、2865 / 3761.9ms。以上阶段不可直接相加求分位数。

判断与限制： SQL共180次、RAG共120次实跑。SQL题中仅3题查询 invoice_line，7题invoice、10题维表控制；不能把总耗时小幅变化推广到所有大表扫描。独立EXPLAIN全明细SUM实际扫描2240 / 10000 / 100000行，执行0.388 / 1.613 / 15.441ms。RAG两个 rag-03变体在两档共6次缺少关键答案片段；页命中不能计作完整答案正确。RAG启发式匹配38/60、39/60不作为语义准确率。压测副本年份延至2045 / 2245，明确是合成压力数据，业务库仍2021—2025。

证据： 数据规模manifest、SQL实际汇总、SQL逐题结果、RAG汇总、RAG原始回答、规模与成本完整说明、真实命令目录。**验收：实际规模、关联核对、正确性检查、阶段耗时及P50/P90齐全；RAG语义限制已披露。**

13．④消融：全量 schema 对比子图

要求： 同一AW、同21道DEV；全量与④两组走相同生成 / 校验 / 执行 / 评分；统计④自身模型调用及耗时，不给筛选器gold表名。前置完整④还须剪枝、理由及连通检查。

实现与改动： schema_linker.py、pruner.py、d4_aw_ablation.py、ui/app.py。实际FK补桥、已绑定字段保护、入选 / 排除理由及连通性已接入；模型只从真实候选选取。全量组直接使用68表 / 456列 / 90FK登记目录。

同21题指标	全量组	④子图组
主EX / 旧EX	21/21 / 21/21	21/21 / 21/21
已回报全链路输入token	832958	243694
SQL生成输入token	795212	48207
④选表输入token	0（未调用）	157741
端到端P50 / P90 ms	4747.472 / 5438.653	8172.456 / 15855.341
实际模型尝试	22	44

判断： 已回报全链路输入减少 **70.74%** ，SQL生成输入减少93.94%；本次准确率没有提高、整体没有提速。aw-07子图首尝试剪枝超时61417ms，重试成功，整条69871.848ms保留；失败尝试未回报usage，不能把未知token当0或把已知合计当完整账单。只有两主组、21题单次成对运行，未声称统计显著性或四组完整消融。

测试与证据： 两组真实汇总、42条实际响应、逐题SQL / 评分、原始provider记录、13/13实际理由页面检查、理由截图。**验收：对照与前置功能完成；结论是减少已回报输入，同时增加本次端到端耗时。9道AW保留题未预测。**

五、10/13 D4：B 线——多轮与跨源

14．多轮补丁与失效：sp03-26 / 27 / 28

要求： 先复现三段失败，再5段×至少6轮；保存结构化 IntentContract，set / add / remove合并、version加1、旧计划 / 结果失效并重查；分别统计每轮条件和整段成功。

实现与改动： clarify/state.py、extractor.py、service.py、sql_guard.py、pipeline.py。修复旧筛选恢复、TopN不更新、旧指标排序、额外投影、裸占比猜分子及删除筛选；不以聊天历史重新猜替代合同合并。

最终004范围	条件 / 版本	参考SQL轮主EX / 全精度	整段成功
原sp03-26/27/28，5/5/4轮	14/14 / 14/14	10/10 / 10/10	3/3
新五段，各6轮	30/30 / 30/30	30/30 / 30/30	5/5
合计	44/44 / 44/44	40/40 / 40/40	8/8

版本说明： 新第4段最终采用独立 **04-v2** ，只在首句添加“降序”，后5句和所有gold SQL不变。原04未明确主方向，其旧输出及DESC gold争议保留，不能将明确版5/5写成原版5/5。原三段包含4次必要澄清；新30轮没有重复追问已确认条件。原首轮原三段1/3、新五段1/5及中间失败均保留。

证据： 修复说明、最终逐轮报告、最终题面与标准材料、各段原始输入输出目录、实际命令、原04失败。**验收：补丁、失效、原失败回归及明确版五段验收完成；新增材料人工核对及原04方向保留。**

15．两类跨源：SQL→文档、文档→SQL

要求： 前一步的真实结果决定后一步输入；同一请求串起数据库与文档，复用已有SQL、RAG和③；6道跨源题、实际界面显示两步。

实现与改动： fusion/planner.py已经实现，截图中的“目录还是空的”属于历史观察。SQL→文档先查冠军ID / 名称，再按 `entity_ref` 精确匹配介绍；文档→SQL先检索客单价逐字定义，把聚合、粒度、字段及源SHA送入真实生成输入并执行前校验。未把文档原SQL绕过校验直接执行。

开发题	最新007实际结果
cross-01	全库冠军Iron Maiden，artist_id90、138.60，匹配风格文档引用
cross-02	2024冠军Iron Maiden、33.66，期间与文档匹配
cross-03	范围只有U2介绍时保留真实冠军，返回文档不足；不借用U2资料
cross-04	手册定义驱动2024美国客户逐发票均额6.0942857142857143，21票127.98
cross-05	手册定义驱动2023加拿大客户逐发票均额5.04，11票55.44
cross-06	缺年先NEEDS_CLARIFICATION且无SQL，同session补2024后查询、version1→2

测试与实际结果： 融合模块47/47；最新007 **6/6 符合预期** ，7次API请求，其中5题完成两步、1题按范围正确返回不足。两类完整界面检查合计 **24/24** ，分别来自UI002和UI003两次运行；截图对应005，不伪称007重拍。实际provider输入确认定义真正参与SQL计划。

证据： 六道DEV题、最新API汇总、逐句答案 / 引用及生成输入复核、SQL→文档截图、文档→SQL截图、两类完整界面记录、第二类补测。**验收：两类实际接入、六题及页面联调完成；新六题语义仍保留人工核对。**

六、10/14 D5：截图中尚未执行的安排

16．15:00 代码冻结

要求： 在约定时点固定代码、配置、题库和口径版本，之后只能按明确流程处理问题。

当前状态：尚未执行。 当前有Git提交及实验源码哈希用于追溯，这是D4实验版本记录，不是D5正式冻结。没有创建D5冻结标记、没有将本次打包时间代填为10/14 15:00。

已有证据： D4实测源码清单、对应原字节源码、最终回归退出码。**后续事项：** 02 / 03已完成；冻结前处理本轮已披露的回归问题及仍需核对的D4新增材料；冻结具体时区需团队明确，不从客户端时区猜比赛截止口径。

17．上午全量评测修错；冻结后再跑一遍，生成 final.md

要求： 冻结前开发验证和修错；冻结后固定版本运行全量正式评测、生成final.md，保留集按原方案边界运行。

当前状态：尚未执行。 本轮只有已有DEV实验、模块与实际入口复核，没有提前调用保留题，没有生成D5正式成绩或final.md。旧D1、D2、D3报告中的“final”目录名称不是D5正式冻结报告。

已具备条件： 本轮782模块通过、双数据库恢复且只读5秒超时、评测新旧EX并存、阶段原始响应和版本追溯齐全。**仍需处理：** 本轮专项多轮问题、原04方向与D4新增题目 / 变体核对、RAG缺答案片段；sp03-19已依双方草稿明确Top1并写入新版，旧争议和成绩保留。不能靠改历史成绩消除失败。

七、本次交付核验、入口和附件

本次实际运行 `pwsh -NoProfile -File scripts/start_project.ps1 -NoBrowser` ，退出0，复用Chinook、AW、API和界面；未导入数据库、未发送模型问答。当前页面 `http://127.0.0.1:8501/` ，API文档 `http://127.0.0.1:8000/docs` 。本次入口命令 / 输出 / 健康记录独立保存，不回填到旧实验日志。

在你目前这台电脑上： 进入原项目目录，双击启动项目.cmd，浏览器打开上述主页面。不要用解压到另一路径的副本启动同端口服务；本机既有环境继续用原项目。审核入口是独立HTML，不能代替8501的项目主界面。

给他人或换电脑： 完整解压ZIP，先打开根目录先看这里.html，再按项目入口与换电脑运行说明安装Python3.12依赖、配置自己的密钥 / 密码、首次建立独立Docker库，然后双击启动项目.cmd。本ZIP包含已有BGE-M3权重、文档 / 值 / AW结构索引、公开原PDF和AW数据，不需重新造题或重新下载模型才能看证据。Python虚拟环境、Docker运行卷及真实凭据不能直接移植，需按说明配置。

附件范围： 项目源码与system prompt、测试、历史D1 ~ D4报告、实际命令和原始响应 / 日志、截图、双方审核提取记录、原始公开数据、模型及索引。排除真实.env、所有.runtime私有文件、Git内部文件、虚拟环境、Python缓存及临时目录。历史题库完整保留，仅用于原计划阶段；本次没有阅读或运行新的保留题内容，也不在本报告展开保留题答案。

最终ZIP包含整个项目外层技术资料和完整system目录。文件清单和各文件SHA256在ZIP根目录 `delivery-manifest.json`；密钥扫描、CRC、解压字节校验、相对证据链接及原始资料保护检查在 `交付包核验.json`。本次授权的新版本文件和最小修复单独列明，不能将其写成“所有业务源码未变”。最终压缩包自身的大小、SHA256及全部检查结果另保存在压缩包旁的核验JSON，避免将ZIP自身哈希循环写入ZIP。打开附件需要整个ZIP解压，不能只转发HTML或在压缩预览器中点证据。

八、本轮补测范围、真实失败与版本边界

实际批次	真实结果	使用与限制
新版SQL全部35题	34/35	首轮sql-38误澄清；其余34通过。不可合并后续补测写成一次35/35
新版鲁棒全部21题	21/21	含新robust-23；均为DEV
两gold最终独立补测	2/2	同v3题目，加载最小修复后真实执行；是本次03验收依据
新版AW全部21题	20/21	aw-19剪枝输出包含候选域外表而被安全拒绝；原始失败保留
aw-19独立修复回归	SUCCEEDED；主EX / 旧EX1/1	采用真实候选域的结构化校验，有限重试；不改prompt或放松下游SQL保护
受影响专项29场景 / 52次请求	整段16/29；SQL EX34/44	原始初轮等级15/22；候选保留2/2；分母含1条未执行续问。并非全通过
最终模块回归	782 passed / 0 skipped / 17.41秒	含新版本路径、题库应用、TopN及候选域边界；模块成功不代替全部真实对话成功

AW首轮、aw-19单题实际回归、专项首轮及逐轮材料、专项问题分类、本次原始命令 / 回归输出、历史来源保护记录。新的API/provider记录独立保存在 runtime-002 与 provider-live-002，已有实验输出不覆盖。

仍存在的问题： sp03-07日期补丁后分子绑定被拒绝、sp03-08年份续问丢失客户排名、sp03-24重复确认账单来源产生冲突、sp03-30客户排名切换曲目时旧分组未失效。这四项已定位并保留实际失败，按本次用户收敛到02 / 03的要求未额外改多轮业务。另有空结果列映射、同比返回列及Top10未声明并列边界的评分限制；这些不能通过改gold消除。L1默认来源标记已做最小一致性修复，但没有重跑全部29段，不宣称该批次等级成绩已经提高。

上述新版批次为正确性回归，并发运行不用于新效率结论。12 / 13条中的D4性能及消融是当时固定源码、目录和配置的实测，更新目录 / 最小修复后没有重新跑180 / 120次规模测试或两组消融，不能声称旧耗时是新版本测得。14条原三段和新增五段的历史成功也不能掩盖本轮新专项失败。

验收边界汇总： 01五项口径已生效；02已使用双方审核正式应用；03新gold已正式版本化并真实补测2/2；04 ~ 15保留当时实现和开发证据及本轮新增限制；16 ~ 17为D5尚未执行。735项不需要重做审核。未调用保留题生成预测、不提前计算正式保留成绩，不填A/B签名或虚构人工日期。