D1 原清单十四项逐项验收与证据

验收记录日期：2026-10-10 | America/Chicago

本文件逐条对应用户本次清单。当前D1工程和数据准备完成；QA下载地址调整、当前协议双方确认及未来功能边界分别写明。当前代码新回归159项通过，工程53/53通过；早先57项工程（含4条live）与149项测试保留历史。

本 PDF 用于直接阅读逐项验收。证据文件的位置对应已提供的 ZIP，按名称和行号即可核查；本文件不使用本机 E:/ 链接。英文事实段已翻译为中文，验收结论和数据保持一致。

上午共同事项

shared-01 | 上午共同

原要求：git init、私有远程仓库、§3.7 目录

验收状态：完成（未来功能按排期）

实际事实：19个计划目录已存在；私有Git仓库已上传并核验。

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-shared-evidence.json	
notes/D1目录对照.md	

shared-02 | 上午共同

原要求：共享 schemas.py 已建立，A/B 同意当前版本；后续改动双方同意

验收状态：完成（当前协议双方已确认）

实际事实：用户确认A/B同意当前版本，含1起物理页约定；后续实质修改必须双方同意。

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-shared-evidence.json	
notes/共享协议确认.md	

A | 数据库与模型接入

A01 | A

原要求：Compose 起 Chinook PG；qa_reader；表名与年份

验收状态：完成

实际事实：Compose 服务 chinook-pg 为 running/healthy；PostgreSQL 16.15；只读 qa_reader：11 表 SELECT=true/write=false；非超级用户，无创建库/角色/复制/RLS 绕过权限；public 的 11 表均 snake_case，64 列，11 条实际外键约束；invoice 2021-01-01T00:00:00 至 2025-12-22T00:00:00，5 个年份 2021-2025；只读默认 on、statement_timeout=5s；旧文案的 13 外键与实际数据库/JSON 不符，应更正为 11

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-a-evidence.md	
docker-compose.yml	4
scripts/bootstrap_db.py	127
data/db/db_check.json	
data/catalog/chinook.yaml	
eval/reports/d1-acceptance/a-review.json	

A02 | A

原要求：查 /models 真实 model id 写入 .env；测试 JSON 输出

验收状态：完成

实际事实：scripts/check_llm.py 实际调用 OpenAI-compatible SDK models.list，等价 GET /models；未按字面 curl 运行，凭据仅在本地读入请求；2026-10-10T11:37:18Z 记录模型 deepseek-flash，账号可用列表 deepseek-flash/deepseek-v4-pro；真实 JSON probe ok=true/message=接入成功，response_format=json_object；1 次 LLM、136 total_tokens、JSON 字段校验成功；当前 Settings 读入的 model 仍为 deepseek-flash；未读取或输出 .env 内容与密钥；无需降级为纯文本 JSON

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-a-evidence.md	
notes/model-check.json	
scripts/check_llm.py	22
qa_agent/llm.py	44
qa_agent/llm.py	92

A | 统一调用、追踪与 NL2SQL

A03 | A

原要求：llm.py 统一调用/超时/重试/token；trace.py @traced

验收状态：完成（本轮补齐）

实际事实：JsonLLM 统一模型调用：60s 默认超时，SDK 隐藏重试关闭，默认请求内总尝试上限 3（包含 SQL 修复/JSON 和网络重试），真实 usage 写 Step；本次发现旧实现只有 TraceRecorder.step，已新增真实 @traced 并接入 execute_sql；pipeline 外层 sql_exec 已移除避免双计；仅显式白名单 sql/db_id/row_count/columns/truncated 进入摘要，不自动记录 args/kwargs 或 DSN；错误利用原 step 做脱敏并保留原异常；同步/异步工具可用；trace 显式属于请求，无共享全局列表；Step 和所有返回协议保持不变；针对性回归 39 passed/0 skipped，2.51s；含新 8 项 trace 测试，均未调用真实模型

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-a-evidence.md	
qa_agent/llm.py	30
qa_agent/trace.py	60
qa_agent/sql/executor.py	69
qa_agent/pipeline.py	106
tests/test_trace.py	

A04 | A

原要求：NL2SQL v0：目录→生成→SQLGlot 校验→只读执行

验收状态：完成

实际事实：真实结构目录由 PG 导出，load_catalog→generate_sql→validate_sql→execute_sql；SQLGlot AST + qualification 验证真实表列、函数及完整作用域；单业务表限定；拒绝写操作、多语句、未知列与无业务表常量；executor 使用新只读事务、server cursor/max 200 行、5s 服务器超时；NULL、0、空表严格区分；修正版 21 dev 实际模型预测 21/21 执行结果匹配，exploratory_ex=1.0，平均 3405.886ms；正式分数待人工 gold 接受

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-a-evidence.md	
qa_agent/pipeline.py	80
qa_agent/pipeline.py	89
qa_agent/pipeline.py	94
qa_agent/pipeline.py	106
qa_agent/sql/validator.py	67
qa_agent/sql/executor.py	86
eval/reports/d1-acceptance/sql-dev/report.json	

A | 题集、gold 与评测

A05 | A

原要求：30 道单表题；gold 逐条跑并保存结果；run_eval.py 计算 EX

验收状态：完成；正式人工审核另列

实际事实：原 30 题＝21 dev/9 holdout，9 类；gold 实际执行 30 次、30/30 原记录逐字一致，保存 gold_sql/gold_columns/gold_result/review_hash；独立修正版仅改 sql-11/22/24，27 项与父题集相同、保留 9 题相同；3 条改动 SQL 已实际执行保存；sql-11 正确 ROUND(AVG(total),2)=5.65；sql-22/24明确 first_name 不包含 last_name；run_eval 调 compare_results，按成功匹配数量/全部选中题计算 EX；失败计入分母，保存请求/响应、实际模型/耗时/版本；当前人工接受 0/30，正式评测被阻止；现有 21/21 属于新题集探索分数，不能覆盖原 19/21；保留题模型预测 0

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-a-evidence.md	
eval/datasets/nl2sql_chinook.jsonl	
eval/datasets/nl2sql_chinook_d1_acceptance.jsonl	
eval/datasets/nl2sql_chinook_d1_acceptance.manifest.json	
eval/reports/d1-acceptance/a-review.json	
eval/run_eval.py	152
eval/run_eval.py	181
eval/metrics.py	85

A | 给 B 的交接与地区口径

A06 | A

原要求：跑附录 C Top 艺术家 SQL 并给 B 名单

验收状态：完成

实际事实：已保存原查询 SQL、Top10 名单和收入定义；本次只读重新查数与交接数据完全一致；Top3：Iron Maiden 138.60、U2 105.93、Metallica 90.09；未推断币种；A_to_B_chinook.{json,md} 已进双方共享私有 Git；名单含 Lost/The Office 电视内容，后续知识库需核对实体类型；当前可证明材料在共享仓库，不证明 B 已另行阅读；跨源文档实现属于后续计划

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-a-evidence.md	
scripts/check_db.py	18
data/handoff/A_to_B_chinook.json	
data/handoff/A_to_B_chinook.md	
notes/B接口交接.md	132

A07 | A

原要求：跑地区口径 SQL 并决定 03 演示例子是否更换

验收状态：完成

实际事实：实际比较 412 张发票，非空不同数 0、NULL-aware不同数 0、含 NULL 数 0；与保存交接记录完全一致；客户所在地与账单地址国家仍是不同业务含义；当前 Chinook 不能演示两口径导致数值差异；03 澄清演示应改成缺比较年度、最受欢迎定义或 Rock/Rock And Roll；D1 完成取数和更换决定，正式澄清实现/设计文档改写为 D3；原 03 资料仍有地区口径示例，不能声称已改写原 03

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-a-evidence.md	
scripts/check_db.py	29
data/handoff/A_to_B_chinook.json	
data/handoff/A_to_B_chinook.md	
notes/references/项目方案.md	116

B | 资料准备与 RAG 实现

B-1 | B

原要求：用 hf-mirror 下载 OHR-Bench qas_v2.json 和 PDF，六域各一份并盘点语言

验收状态：完成；QA来源调整

实际事实：本轮逐项核对实际通过 hf-mirror 的 ZIP HTTP Range 下载六份固定版本原始 PDF；六份的实际 SHA256 和 CRC 均与原语料 PDF 一致。qas_v2.json 的镜像根地址返回 404，保留 SHA 匹配的固定官方 GitHub 原始 QA 版本。历史官方下载记录及正在使用的 PDF / 索引均保持不变。

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-b-evidence.md	
scripts/prepare_rag_data.py	
data/docs/source_manifest.json	
data/docs/manifest.csv	
notes/D1执行指导书.md	
eval/reports/d1-acceptance/requested-download-route.json	
eval/reports/d1-acceptance/requested-mirror-pdfs.json	

B-2 | B

原要求：PDF parsers/chunker/index(BGE-M3+BM25)/retriever/answer，编号引用

验收状态：完成

实际事实：已实现真实 PDF 文本与版面解析、按页保留来源片段，以及 1527×1024 的真实 BGE-M3 int8 CPU 向量。采用词法与稠密检索的 RRF 融合，支持 doc_id 范围限制、来源与哈希核对；编号引用会按实际提供的证据进行校验。

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-b-evidence.md	
qa_agent/rag/parsers.py	
qa_agent/rag/chunker.py	
qa_agent/rag/index.py	
qa_agent/rag/embeddings.py	
qa_agent/rag/retriever.py	
qa_agent/rag/answer.py	
notes/rag-corpus-check.json	
eval/reports/d1-acceptance/rag-dev/report.md	

B | 界面与问答题集

B-3 | B

原要求：Streamlit 提问框、来源选择、三个折叠面板

验收状态：完成（本轮补齐）

实际事实：本轮按原清单核对前，界面只有两个折叠面板；现已补为“SQL 与结果 / 引用来源 / 处理步骤与耗时”，两条链路以及未提问状态都常驻显示。展示实际 SQL / 表格 / 数据库标识、真实证据及 PDF 页码、实际处理步骤；暂无内容的面板显示明确占位说明。API、共享协议及运行时检索逻辑未改变。

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-b-evidence.md	
ui/app.py	
tests/test_ui_app.py	
eval/reports/d1-acceptance/requested-ui-tests.txt	
eval/reports/d1-acceptance/requested-ui-smoke.json	
eval/reports/d1-acceptance/requested-engineering.json	

B-4 | B

原要求：从原 OHR QA 挑选20道 evidence_source=text 的题

验收状态：完成

实际事实：全部 20 道题均保留原始上游 ID、问题、答案、完整来源 QA、SHA256 以及原始 PDF 物理页的准确引文；划分为 14 道 dev / 6 道 holdout。人工 gold 审核仍待完成，6 道保留题的模型预测仍为 0。

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-b-evidence.md	
eval/datasets/rag_ohr.jsonl	
eval/datasets/rag_ohr.manifest.json	
eval/datasets/rag_machine_audit.json	
eval/rag_build_gold.py	

晚上联调与验收说明

JOINT-EVENING | 晚上联调

原要求：界面各问一道 SQL/文档题；notes/screenshots/D1-*.png；数字写dev-log.md

验收状态：完成

实际事实：原 notes 截图保留。修正后的真实界面联调得到 SQL 结果 5，以及中文 MacBook iMovie 文档回答 [E1] / PDF 物理第 3 页；未提问、SQL、切换来源和文档状态的三面板检查在内，共 8 项通过。截图按字节原样保存为 notes/screenshots/D1-验收-*.png。既有 35 题开发基准未重跑；本次界面 2 个请求 / 3 个 LLM 步骤不计入基准。

证据文件（ZIP 内相对位置）	行号
eval/reports/d1-acceptance/requested-b-evidence.md	
notes/ui-smoke.json	
notes/screenshots/D1-evidence.json	
notes/dev-log.md	
eval/reports/d1-acceptance/ui-smoke.json	
eval/reports/d1-acceptance/requested-ui-smoke.json	

本轮新增真模型请求仅为新页面SQL和文档各一道，观察3个LLM步骤；不重跑35题旧开发基准，不预测15道保留题。

资料路线调整不是更换题库：六份镜像PDF与原件SHA256逐一相同，QA仍为同一固定官方版本。原PDF、索引、题库及原开发报告内容保留。

D1的30条gold实际执行与保存已完成。标准答案人工业务接受和正式模型成绩另行完成，不把AI复核填成真人审核。

后续nlu/clarify/fusion/aliases/rules仅补目录说明，未宣称D2-D4功能已经完成。