中国电子杯 · 赛题八

D1 验收报告与操作手册

2026-10-10 | A：后端 / SQL · B：文档 / 页面

同一页面已接入真实 SQL 与指定文档问答。工程实测、AI 审阅、人工接受和外部确认各有独立记录。

验收项	本次实测	解释
工程回归	159 项通过；退出码 0	工程行为，非自然语言准确率
SQL 修正版开发集	21/21；100.00%	独立修正版，gold 尚待人工接受
SQL 平均 HTTP 耗时	3.406 秒	本次实际 21 条请求
RAG 开发集	14 条实际请求；成功 14/14	引用机械检查与语义复核分开
RAG 原文真实性	14/14	引用可在指定 PDF 物理页找到
RAG 平均 HTTP 耗时	3.184 秒	本次实际 14 条请求
知识库	6 份，261 页，1527 片段	六域原生 PDF；向量和哈希有记录
人工 gold 接受	SQL 0/30；RAG 0/20	AI 复核没有签署团队人工审核

SQL 使用另建的修正版；与旧 19/21 不是完全相同题集，不能把差值描述成模型提分。RAG 引用机械通过与 AI 复核都不替代人工签字。

生成时间：2026-10-10T08:52:15-05:00

生成时提交：b27a60bc283e2c79d187f44655144a401a142629

01 D1 范围与 A 线逐项验收

D1 目标：同一界面可回答一道库题、一份指定文档的问题，展示实际 SQL 或原文，并保存第一份可复查基线。D2-D9 能力不混入今日工程验收。

编号	计划要求	记录状态
S01	确认学校初赛截止日期及具体时刻、提交入口、额外材料/PPT	外部待确认
S02	确认本机与B电脑开发环境/Docker可用	本机通过，远机待核
S03	确定A/B职责	通过
S04	初始化Git及建立私有远程协作	通过
S05	按代码目录建立仓库骨架	通过
S06	确定共享schemas及输入/响应/步骤/证据协议	通过，双方已确认
A01	起Chinook PostgreSQL并核对实际表名、年份范围	通过
A02	只读qa_reader和SQL超时	通过
A03	查询账号可用model id、真实JSON接入	通过
A04	统一LLM超时、有限重试、token及trace	通过
A05	真实schema目录和中文字段语义	通过
A06	NL2SQL v0：目录→生成→AST校验→只读执行	通过
A07	30道单表gold，逐条执行并保存结果	机器准备通过
A08	人工核对SQL题意、标准SQL与结果；正式开发EX	人工审核待完成
A09	评测脚本计算EX、保存真实基线	草稿基线通过
A10	跑Top艺术家SQL并交名单给B	通过
A11	核对客户国与账单国地区口径差异	通过

标准 SQL 的只读独立执行是 gold 审计；它没有预测保留题。原表名为 snake_case，发票日期2021-2025；只读账号、5秒 SQL 超时、200 行展示边界已有实际记录。

02 B 线与晚上联调验收

编号	计划要求	记录状态
B01	固定OHR官方qas_v2及六域PDF、盘点语言	通过，来源调整已记录
B02	PDF解析、章节与真实文字/页码切片	通过
B03	真实BGE-M3 + BM25索引	通过
B04	先指定单文档，再混合检索	通过
B05	带编号证据回答、引用约束和真实错误	通过
B06	Streamlit来源选择、答案、SQL/表/引用/步骤面板	通过
B07	20道官方evidence_source=text QA、固定14dev/6holdout	机器准备通过
B08	人工核对20道RAG gold及14条真实开发答案	人工审核待完成
B09	保存真实RAG开发基线、失败、耗时	草稿基线通过
I01	同一API接入SQL与文档，真实统一响应	通过
I02	界面数据库题、文档题各跑通且给证据	通过
I03	保存D1真实截图	通过
I04	首条dev-log记录数字、问题及D2待修	通过
I05	环境依赖、README、快速本机启动	D1 范围通过
I06	保护凭据并保证题库/运行库分离	通过

六域原生 PDF 共261物理页，255页有原生文字，索引1527片段。实际BM25+BGE-M3 RRF，CPU/int8、1024维、Top-K5；不是仅有配置。

1402/1527片段有可靠块坐标；226片段存在不完整句界。最大600字符、目标重叠80、不跨页；长句或物理页末不宣称完整。

当前页面显示原文与完整原页；未声明逐字高亮或 OCR。内部物理页从1起，OHR原始0起仅转换一次。跨电脑从零复现按D8计划实际执行，今天不冒称已通过。

03 新开发集、修复与 AI 复核

修订项	发现及处理
sql-11	原题要求保留两位小数；原 AVG(total) 返回多位小数。修正版在 SQL 层执行 ROUND 并保存真实结果，不依靠评测器金额量化掩盖显示差异。；原 SQL：SELECT AVG(total) AS average_total FROM invoice;；原结果：[{"average_total":"5.6519417475728155"}]。修正版：SELECT ROUND(AVG(total), 2) AS average_total FROM invoice;；真实结果：[{"average_total":"5.65"}]
sql-22 / sql-24	“名字”含义可歧义，原 gold 只取 first_name；独立修正版明确 first_name 名字段；团队仍需确认业务口径
RAG 片段上下文	原草稿 rag-16/19 引用上下文与回答存在缺口；自然句界/表格行切片及不完整边界标记已改进；新模型在完整证据上实际回答，经逐项 AI 复核；未修改回答 prompt
协议与旧文档	旧指南 Python3.11、0起页码、Top8 与实现不同；指南改 Python3.12、1起物理页、Top-K5；原官方页索引仍0起
仓库协作	原工程只有本地 Git；已创建私有仓库；推送验证以 repository 记录为准

SQL修正版：21/21，exploratory_ex=100.00%，平均3.406秒。原19/21报告不覆盖。新版本改3条开发题的口径，不能作同题集提分比较。

RAG机械检查	本次结果
status_succeeded	14/14
all_evidence_from_selected_doc	14/14
all_evidence_text_authentic	14/14
retrieval_gold_page_hit	14/14
evidence_gold_page_hit	14/14
answer_has_known_evidence_id	14/14

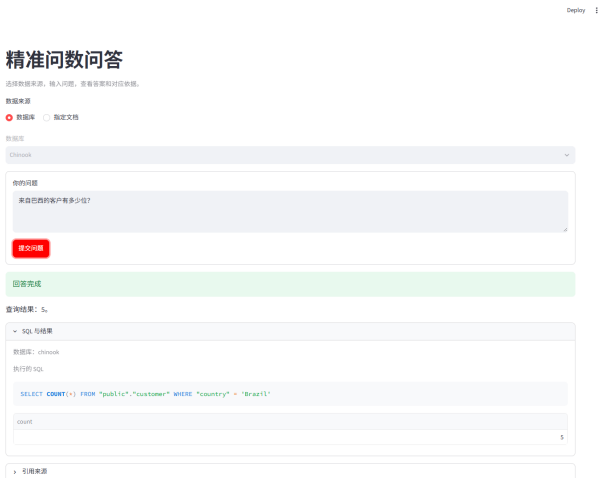
B 新回答 AI 审阅汇总：{"semantic_correctness":{"correct":14,"incomplete":0},"claim_support":{"complete":14,"incomplete":0},"joint_pass":14,"denominator":14}

人工 gold 接受：SQL 0/30，RAG 0/20。没有自动署名 A 或 B。正式EX/忠实度仍需真实人工流程。

04 页面演示与记录检查

实际浏览器检查（8项分组）	结果
SQL回答/查询显示、文档回答/证据显示	2/2
引用点击、原PDF物理页展示	2/2
SQL、文档回答各有三个固定面板	2/2
未提问、切换来源各有三个固定面板	2/2

浏览器异常：[]





上图为实际浏览器截图缩略图，完整PNG与请求编号见notes/screenshots及最新requested-ui-smoke.json；旧版本截图与记录保留。

本次21SQL＋14RAG为35条开发预测，接口token来自实际用量；该汇总不含旧草稿、探测、页面演示和工程边界调用。未提供账单，不虚构费用。

本次35条开发请求用量：{"questions":35,"holdout_predictions":0,"llm_attempts":35,"llm_calls_with_usage":35,"token_totals":{"prompt_tokens":105290,"completion_tokens":2461,"total_tokens":107751,"prompt_cache_hit_tokens":80256,"prompt_cache_miss_tokens":25034}}

实际用量证据：eval/reports/d1-acceptance/model-usage.json。Markdown版本展示完整汇总JSON。

凭据检查	实测
candidate_files_scanned	212
env_ignored	是
env_tracked	否
candidate_credential_hits	[]
history_blobs_scanned	248
history_credential_hits	[]
oversized_files	[]

05 本机启动与操作

本机已准备数据库、模型和索引，直接复用.venv。打开Docker Desktop的Linux引擎后，在项目目录执行：

```
Set-Location -LiteralPath 'E:\中国电子杯-赛题八\system'
.\.venv\Scripts\python.exe --version
docker compose --project-name comagent-d1 ps
.\scripts\start_demo.ps1
```

服务	入口
问数问答页面	http://127.0.0.1:8501
API文档	http://127.0.0.1:8000/docs
数据库	127.0.0.1:55432 / qa_reader

1. 选择Chinook，问“来自巴西的客户有多少位？”，核对答案、实际SQL、结果及步骤。

2. 选择一份登记PDF，使用它的开发题；核对答案、原文归属和物理页。点击引用只切换展示，不再调用模型。

3. 切换来源后不会显示旧来源答案；没有证据时如实EMPTY_RESULT，未实现能力为UNSUPPORTED，真实执行错误为FAILED。

修改.env或公共配置后重启自己的API。页面刷新不会重载服务配置；脚本复用健康API。Ctrl+C停止前台页面，后台API保持运行。端口被占用时先核对本人进程，不结束陌生PID。

Evidence.page与原页API均从1起，封面计页。页面不再加1；原OHR的0起索引只在转换入口加1一次。

06 API诊断与错误排查

```
Invoke-RestMethod 'http://127.0.0.1:8000/health'
Invoke-RestMethod 'http://127.0.0.1:8000/api/documents'
Invoke-WebRequest 'http://127.0.0.1:8501/_stcore/health'
.\.venv\Scripts\python.exe scripts/check_db.py
.\.venv\Scripts\python.exe -m pip check
```

现象	核查与处理
8501无法访问	检查Streamlit终端与_stcore/health；已有页面服务直接打开。
database_ready=false	检查Docker Linux引擎、compose ps和check_db；保留数据库命名卷。
旧配置仍生效	核对本人API启动进程并重启；仅刷新页面无效。
文档ready=false	核对manifest/PDF哈希/索引；按固定来源准备并重新ingest。
认证、余额或网络错误	读取真实error与model-check，在本地修正；不打印key，不用固定答案代替失败。
EMPTY_RESULT	所选文档证据不足；不偷偷切换来源。
UNSUPPORTED	请求可能超出单表、单文档范围；按后续计划实现。
READINESS_ONLY	正式评测条件不足，预测0；完成实际审核与服务准备后再运行。

HTTP 200不等于业务成功，核对status/error/steps；llm_configured=true只表明读取到配置，真实可用性以实际调用为准。SQL结果的COUNT 0、零行和SUM NULL分开表达。

SQL 请求结构：session_id、message、scope={route:sql,db_id:chinook,doc_ids:[]}。文档请求route=doc、db_id=null、doc_ids恰好一个登记ID；UI只通过HTTP调用统一API。

07 私有协作与新电脑准备

私有仓库：gaara119/china-electronics-cup-task8-comagent。private字段=是；上传状态=main_uploaded_verified

B的私有仓库权限已添加，依据用户在2026-10-10的确认；另一台电脑的登录、克隆及环境准备尚未实际验证。源码及清单通过Git同步，本地.env/.venv/PDF缓存/模型/索引按忽略规则独立准备。

```
git clone 'https://github.com/gaara119/china-electronics-cup-task8-comagent.git' 'E:\中国电子杯-赛题八\system'
Set-Location -LiteralPath 'E:\中国电子杯-赛题八\system'
py -3.12 -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
if (-not (Test-Path -LiteralPath '.env')) {
    Copy-Item -LiteralPath '.env.example' -Destination '.env'
}
# 在本地编辑 .env，再执行后面的准备命令。
.\.venv\Scripts\python.exe scripts/bootstrap_db.py
.\.venv\Scripts\python.exe scripts/check_db.py
.\.venv\Scripts\python.exe scripts/build_catalog.py
.\.venv\Scripts\python.exe scripts/prepare_rag_data.py --selected-d1
.\.venv\Scripts\python.exe scripts/download_embeddings.py
.\.venv\Scripts\python.exe scripts/check_embeddings.py
.\.venv\Scripts\python.exe scripts/ingest_docs.py
.\scripts\start_demo.ps1
```

.env在新机编辑：模型key、管理员及只读数据库口令、匹配的CHINOOK_DB_URL；保留CPU/int8/TopK5。模型约587MB，索引必须实际CPU编码。不要复制对方.venv或覆盖现有.env。

127.0.0.1指当前电脑；另一台电脑尚未实际复现。准备流程不是远机通过记录，D8真正从零操作后留版本、截图及检查证据。

08 人工接受与正式评测

先看SQL修正版审核表eval/datasets/review_d1_acceptance/gold_review.md。sql-11要求平均总额保留两位小数，修正版ROUND(AVG(total),2)实际5.65；sql-22/24仅first_name。原版接受记录不能代替修正版审核。

```
# 仅在实际核对以下题目之后记录；替换真实审核人。
.\.venv\Scripts\python.exe scripts/review_gold.py `
  --dataset eval/datasets/nl2sql_chinook_d1_acceptance.jsonl `
  --output eval/datasets/review_d1_acceptance `
  --accept sql-01,sql-02 --reviewer '实际审核人'
# 全部21道开发gold有效接受后，运行此修正版的正式评测。
.\.venv\Scripts\python.exe -m eval.run_eval `
  --dataset eval/datasets/nl2sql_chinook_d1_acceptance.jsonl
```

RAG gold审核对照原PDF物理页核题意、答案和证据；实际回答再核正确、完整及每项事实支持。两项审核分开。

```
# 仅记录实际已核对的题目。
.\.venv\Scripts\python.exe scripts/review_rag_gold.py `
  --dataset eval/datasets/rag_ohr.jsonl `
  --accept rag-02,rag-03 --reviewer '实际审核人'
# 全部14道开发gold有效接受后运行。
.\.venv\Scripts\python.exe -m eval.rag_run_eval `
  --dataset eval/datasets/rag_ohr.jsonl
```

示例--accept仅在实际已核对这些ID时使用，--reviewer填真实审核人。Markdown勾选是笔记，脚本写入内容哈希绑定的接受记录；题意、gold或split变更使原接受失效。

默认创建新评测目录，历史报告不覆盖。没有真实人工接受时只能--draft-gold探索；D1不预测SQL9道与RAG6道保留题，冻结后按既定纪律评测。

09 外部事项、D2计划与证据索引

学校截止时刻、提交平台和额外PPT目前暂无正式通知，保持外部待确认；计划D9倒排不是学校已确认期限。当前协议已获双方同意（用户确认），后续修改须双方同意具体版本；B私有仓库权限已添加（用户确认），远机准备仍待实际验证。

后续阶段	范围
D2	要素级联/改写、50SQL及30鲁棒题
D2	多格式/OCR≥10文档、业务口径手册、30RAG及完善引用/数字核验
D3	AW④与③澄清状态机/卡片
D4	多轮、跨源、消融与两规模效率
D5	冻结全评测、评测看板、从零一键启动与final报告
D6–D9	最终设计报告/实现说明书Word+PDF、演示视频与ZIP
D8	另一台电脑从零解压README复现

证据全部保存在system；查数字看JSON，查单题看原始responses/predictions，查引用回原PDF。报告生成不会调用模型或接受gold。

eval/reports/d1-acceptance/checklist.{md,json}

eval/reports/d1-acceptance/{engineering,secret-scan,ui-smoke}.json

eval/reports/d1-acceptance/sql-dev/report.{md,json}

eval/reports/d1-acceptance/rag-dev/report.{md,json}

eval/reports/d1-acceptance/a-review.{md,json}

eval/reports/d1-acceptance/b-review-final.{md,json}

eval/reports/d1-acceptance/model-usage.json

notes/{github-repository,rag-corpus-check,rag-index-check}.json

notes/D1协作交接.md；notes/D1执行指导书.md

scripts/build_d1_handbook.py；README.md

10 原清单证据：上午共同与A

本页逐条对应用户10/10清单。详细源代码行号、数据库原始值和链接见requested-d1-evidence.md/json，保持原始测试与旧评测记录。

编号	要求与状态	证据入口
shared-01	git init、私有远程仓库、§3.7 目录；完成（未来功能按排期）	requested-shared-evidence.json
shared-02	共享 schemas.py 已建立，A/B 同意当前版本；后续改动双方同意；完成（当前协议双方已确认）	requested-shared-evidence.json
A01	Compose 起 Chinook PG；qa_reader；表名与年份；完成	requested-a-evidence.json
A02	查 /models 真实 model id 写入 .env；测试 JSON 输出；完成	requested-a-evidence.json
A03	llm.py 统一调用/超时/重试/token；trace.py @traced；完成（本轮补齐）	requested-a-evidence.json
A04	NL2SQL v0：目录→生成→SQLGlot 校验→只读执行；完成	requested-a-evidence.json
A05	30 道单表题；gold 逐条跑并保存结果；run_eval.py 计算 EX；完成；正式人工审核另列	requested-a-evidence.json
A06	跑附录 C Top 艺术家 SQL 并给 B 名单；完成	requested-a-evidence.json
A07	跑地区口径 SQL 并决定 03 演示例子是否更换；完成	requested-a-evidence.json

数据库实测11表、64列、11外键，invoice 2021-2025，qa_reader默认只读on/5s。旧文本13外键已按真实pg_constraint和原审计JSON更正为11。

当前schemas文件未修改，双方同意绑定SHA256：60b2816559f347dd60734f80563ae75fb453ab3903b528ed2d6075316b190445。未来变更须双方同意新版本。

@traced已接入真实sql_exec，避免重复计时且不记录DSN。最新工程53/53，pytest159/0skip；旧57项含4个live边界题，本轮未重跑它们。

Top艺术家前三：Iron Maiden 138.60、U2 105.93、Metallica 90.09。地区比较412张发票、差异0，决定更换澄清演示；原03设计正文没有冒称已改写。

11 原清单证据：B与晚上联调

编号	要求与状态	证据入口
B-1	用 hf-mirror 下载 OHR-Bench qas_v2.json 和 PDF，六域各一份并盘点语言；完成；QA来源调整	requested-b-evidence.json
B-2	PDF parsers/chunker/index(BGE-M3+BM25)/retriever/answer，编号引用；完成	requested-b-evidence.json
B-3	Streamlit 提问框、来源选择、三个折叠面板；完成（本轮补齐）	requested-b-evidence.json
B-4	从原 OHR QA 挑选20道 evidence_source=text 的题；完成	requested-b-evidence.json
JOINT-EVENING	界面各问一道 SQL/文档题；notes/screenshots/D1-*.png；数字写 dev-log.md；完成	requested-b-evidence.json

六份PDF本轮经hf-mirror真实下载，CRC/SHA256均与原资料一致，原PDF和索引未变。镜像独立qas_v2.json返回404，QA继续取固定官方GitHub版本；不是更换题库。

原qas_v2共8498条；20道原始text题逐条来源核验通过，14dev/6holdout。六域各一份全英文PDF，共261物理页、1527×1024混合索引。

三固定面板：SQL与结果、引用来源、处理步骤与耗时；空态、SQL、切换来源、文档四种实际页面状态均确认3个。最新浏览器8/8检查、无page error。

新SQL实答巴西客户5；新文档实答iMovie [E1]、物理第3页。两个实际UI问题观察3个LLM步骤，不纳入原35题基准，不预测保留题。

新三图：notes/screenshots/D1-验收-sql.png、D1-验收-rag.png、D1-验收-rag-trace.png。图像SHA与trace在D1-evidence.json；旧截图原样保留。

最新工程：eval/reports/d1-acceptance/requested-engineering.json；页面：requested-ui-smoke.json；下载：requested-mirror-pdfs.json及requested-download-route.json；目录：notes/D1目录对照.md；协议：notes/共享协议确认.md。